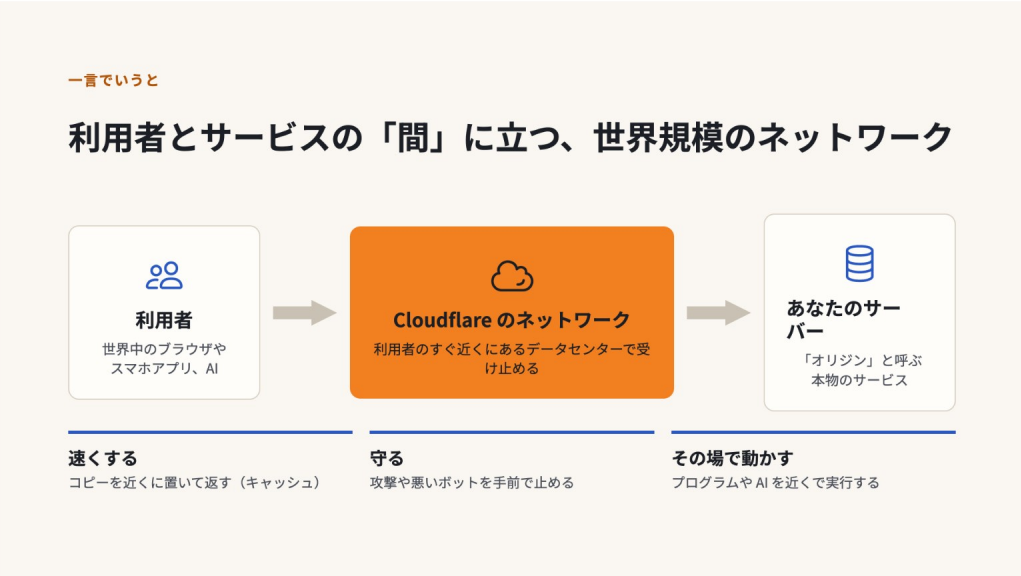


この講義では、Cloudflare が何をしている会社なのかを押さえたうえで、創業から今日までの発展を「なぜそうなったのか」という理由とセットで追います。最後に AI 関連の機能を整理し、ハンズオンにつなげます。数字や日付はすべて Cloudflare 公式ブログ・公式サイト・決算資料で確認したものです。



ゴールは3つです。1つ目と2つ目は講義パート、3つ目はハンズオンパートで扱います。



Cloudflare を一言でいうと、利用者とサービスの間に立つ巨大なネットワークです。間に立っているので、コピーを返して速くする、攻撃を止めて守る、さらにその場でプログラムを動かす、ということができます。この3つ目が、後で出てくる Workers や Workers AI につながります。



数字で規模感をつかみます。335都市、125か国以上にデータセンターがあり、Webの HTTP トラフィックのおよそ2割が Cloudflare を通っています。売上も伸び続けていて、2026年第2四半期は前年同期比36%増です。



専門用語を4つだけ押さえます。DNS は住所録、CDN はコピーの配送網、エッジは利用者に近い場所、サーバーレスはサーバーの面倒を見なくてよい実行方式です。AI に例えると、サーバーレスは「モデルの API を呼ぶだけで GPU の管理はしない」のと同じ感覚です。



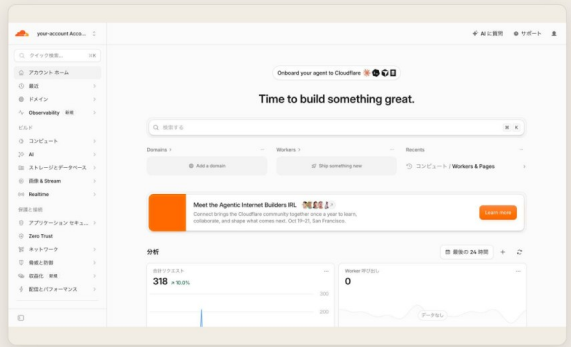
サービスは大きく4つの領域に分けられます。左の2つが昔からの主力事業で、Webサイトや社内ネットワークを守るものです。右の2つ、開発者プラットフォームと AI が、最近 AI の文脈で話題になっている部分です。大事なのは、4つとも同じネットワークの上に載っていることです。

実際の管理画面

左のメニューが、そのままサービスの地図になっている

「ビルド」の下に**コンピュート・AI・ストレージ**、「保護と接続」の下に**セキュリティ・Zero Trust・ネットワーク**が並ぶ

トップの見出しは「Onboard your agent to Cloudflare」。AI エージェントを前面に出している



2026年10月時点のダッシュボード（日本語表示）。アカウント名などは伏せている

これが実際のダッシュボードです。左のメニューが、先ほどの4つの領域とほぼ対応しています。ホーム画面の一番上に「エージェントを Cloudflare に載せよう」という案内が出ていて、会社として AI エージェントを前面に出していることがわかります。



歴史を一枚で見るとこうなります。最初は Web サイトを守り、速くする会社でした。次に、そのネットワークでお客さんのコードを動かせるようにしました。そしてそこに GPU を置き、AI とエージェントの基盤になっています。それぞれの段階には理由があるので、順に見ていきます。



Cloudflare の原点は、2004年に始まった Project Honey Pot というスパム追跡プロジェクトです。追跡はできたので、次は止めたい。止めるにはサイトの前に立つ必要がある。これが「間に立つネットワーク」という今の形の出発点です。前に立つとコピーも返せるので、ベータ版の段階で速くなる効果も確認されていました。



2014年には、それまで有料だった HTTPS の証明書を、無料の利用者も含めて全員に配りました。理由はミッションで、暗号化されていない Web は盗み見や検閲に弱いからです。ここで押さえておきたいのは、無料で配ると利用者が集まり、流れるデータが増えるほどネットワークが賢くなるという構造です。このあとの発展にも繰り返し出てきます。



2017年の Workers が、今の AI の話につながる一番大きな転換点です。顧客の要望が多様すぎて機能追加が追いつかないので、ネットワークの上で顧客のコードを動かせるようにしました。何百もの拠点すべてで動かすために、仮想マシンではなく Chrome と同じ V8 エンジンの軽い仕組みを選んでいます。起動が一瞬で、ハンズオンでもデプロイが数秒で終わるのはこのおかげです。



コードが動くようになると、次はデータが要ります。データが遠くの別のクラウドにあると、せっかくエッジで動かしても往復で遅くなります。そこでキーバリューストア、状態を持てる Durable Objects、ファイル置き場の R2 と、データの置き場所を揃えていきました。R2 は、データを取り出すたびにかかる料金をゼロにしたことで注目されました。今では Pages は Workers に統合されつつあり、新規の静的サイトも Workers で公開するのが推奨です。



2020年にはパンデミックで、社員がみんな家から仕事をするようになりました。会社のネットワークの中なら安全、という前提が崩れたので、毎回本人と端末を確認する Zero Trust を提供しました。これも、すでに世界中にあるネットワークを別の用途に使い回した例です。AI 時代には、AI エージェントが社内システムにアクセスするときの安全な入口としても使われ始めています。



2023年、ChatGPT のブームの翌年に Workers AI を出しました。当時、AI を自分のサービスに組み込むには GPU を確保する必要があり、ハードルが高かったんです。Cloudflare にはすでにコードを動かす場所があったので、そこに GPU を足すだけで、開発者はいつもの Workers のコードから AI を呼べるようになりました。同時に RAG 用のベクトルデータベースと、外部 AI の通信を管理する AI Gateway も出しています。



MCP は、AI にツールを使わせるための共通の規格です。2025年初めの時点では、MCP サーバーは基本的に自分の PC の中で動かすもので、ブラウザやスマホの AI からは使えませんでした。Cloudflare は、インターネット越しに使えるリモート MCP サーバーを Workers で作って公開する仕組みと、ログインの仕組みを出しました。今日のハンズオンの最後で、これを実際に作ります。



2025年7月1日、Cloudflare は新しいサイトで AI クローラーを標準でブロックすると発表しました。昔の検索エンジンは、ページを読む代わりに訪問者を送ってくれました。でも AI は答えをその場で返すので、サイトに人が来ません。Cloudflare の計測では、読むページ数に対して送ってくる訪問者の少なさが、昔の Google と比べて OpenAI で750倍、Anthropic で3万倍です。インターネットの2割を通しているので、こういう計測ができ、ルールを変える影響力もあります。左下の画像は、AI ボットの通信量を公開している Cloudflare Radar です。

歴史 9　2025年末–2026

エージェントに必要なものを、一か所に揃えにいく

何をしたか

- 2025年12月：AI モデル実行サービスの Replicate を買収完了
- 2026年4月：Sandboxes（エージェント用の隔離された PC）GA、Agent Memory など
- 2026年8月：Workers AI と AI Gateway を一つの窓口に統合
- 2026年9–10月：AI Search GA、エージェントに課金する Monetization Gateway（ベータ）



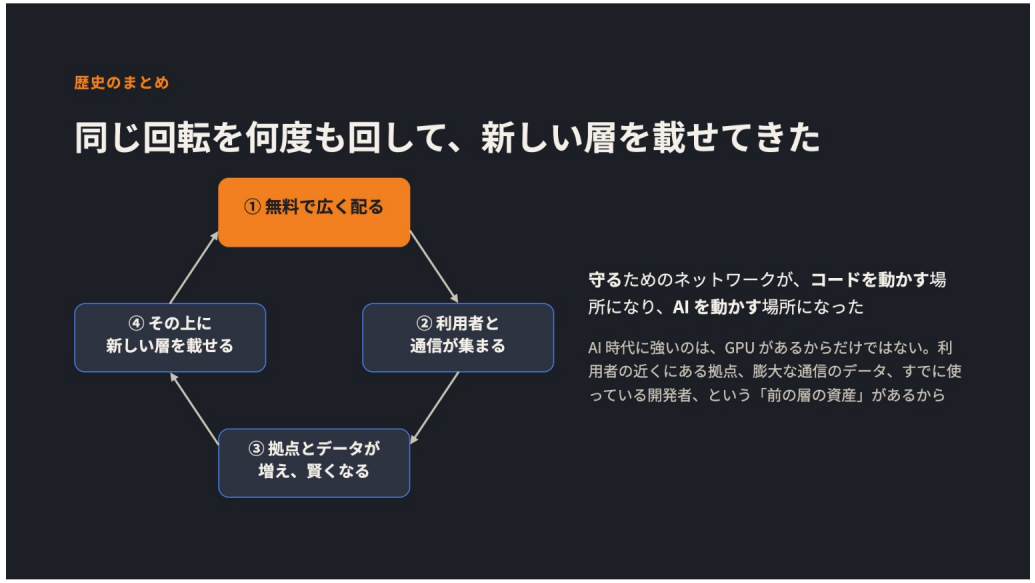
なぜ

エージェントは「考える」だけでなく、**実行する場所・記憶・検索・支払い**まで必要になる

それぞれ別の会社のサービスを組み合わせるより、同じネットワーク上に揃っていれば速く、安く、安全に作れる

出典：blog.cloudflare.com「Why Replicate is joining Cloudflare」、Agents Week 2026（4月・8月）と Birthday Week 2026 のまとめ記事。画像は 2026年10月のダッシュボード

2025年末から2026年にかけては、エージェントに必要な部品を一気に揃えています。モデル実行の Replicate を買収してモデルの品揃えを増やし、エージェントが自由にコマンドを実行できる隔離環境、記憶、検索を出しました。8月には自社の Workers AI と、他社モデルへの窓口だった AI Gateway を一つにまとめています。今のダッシュボードのモデル一覧には、Cloudflare 上で動くモデルと OpenAI や Google のモデルが一緒に並んでいます。さらに、エージェントがサイトやデータを使うときにお金を払う仕組みまで作り始めています。



歴史をまとめると、同じ回転を何度も回しています。無料で広く配ると、利用者と通信が集まり、ネットワークが大きく賢くなる。その上に新しいサービスを載せる。守るためのネットワークがコードの実行場所になり、さらに AI の実行場所になりました。AI の文脈で Cloudflare が強いのは、GPU を持っているからだけではなく、前の層で積み上げた資産があるからです。

AI を作る側の機能

AI アプリやエージェントを作るための部品

サービス	何をするか	ハンズオン
Workers AI	Cloudflare の GPU で AI モデルを動かす。コードから 1 行で呼べる	触る
AI Gateway	どの AI への通信も一か所で記録・キャッシュ・制限する窓口	—
Agents SDK・MCP	エージェントや MCP サーバーを Workers 上で作るための道具	触る
AI Search・Vectorize	自分の資料を AI に検索させる（RAG）	—
Sandboxes	エージェントがコマンドを実行できる、隔離された実行環境	—
Browser Run	エージェントにブラウザを操作させる（旧 Browser Rendering）	—

出典：developers.cloudflare.com、Agents Week 2026 まとめ記事（2026年4月20日・8月10日）

ここからは AI 関連の機能を整理します。まず AI を作る側です。Workers AI がモデルを動かす本体、AI Gateway が通信の窓口、Agents SDK がエージェントや MCP サーバーを作る道具です。自分の資料を検索させる AI Search、エージェントがコマンドを実行できる Sandboxes、ブラウザを操作させる Browser Run もあります。ハンズオンでは Workers AI と MCP を触ります。



もう一つの側面が、AI から守る、あるいは AI からお金を受け取る側の機能です。AI Crawl Control で、どの AI が自分のサイトをどれだけ読んでいるかを見て、許可やブロックを決められます。さらに読んだ量や使った量に応じて支払ってもらう仕組みや、エージェントに API を有料で売る仕組みもあります。HTTP 402 は「支払いが必要」という、昔からあるのにほとんど使われていなかったステータスコードで、エージェント時代になって活用され始めています。



右：ハンズオンで作る MCP サーバーのツールを、Cloudflare の AI Playground から呼んだ画面

MCP の流れを確認します。AI クライアントが MCP サーバーに、どんなツールがあるかを聞きます。質問に合うツールを選んで、引数を付けて呼び出します。返ってきた結果を使って、AI が答えを書きます。リモート MCP では、この MCP サーバーがインターネット上にあります。右の画面は、ハンズオンで作るサイコロのツールを AI が呼び出したところです。AI は乱数を正しく作れませんが、ツールを使えば本物のサイコロの結果を返せます。



無料プランでどこまでできるかです。Workers は1日10万リクエスト、Workers AI は1日1万ニューロンまで無料です。ニューロンは AI の計算量の単位で、今日のハンズオンで何度か試したら32ニューロンでした。R2 だけは、無料枠の中で使う場合でも最初にサブスクリプションの登録が必要で、クレジットカードなどの支払い方法を求められるので注意してください。



ここからハンズオンです。1と2はブラウザだけでできます。3と4はターミナルでコマンドを使います。Node.js のインストールから手順書に書いてあるので、そのとおりに進めてください。